

SCP C



2025 Samsung AI Challenge

Image Caption과 VQA를 활용한 선다형 질문 추론

닉네임 가용성

2025.08

* Contents

1. TEST 데이터 분석

2. 해결 전략


3. 모델 선정

4. 학습

5. 결론

* TEST 데이터 분석

질문 유형



* TEST 데이터 분석

문제 유형

1. 지각 및 장면 이해

- 설명

- 이미지 안에 보이는 것(사물, 사람, 배경, 계절 등)을 관찰하고 묘사하거나 명명하는 질문

- 예시

- What is visually obvious in the image?
- What are the people holding?
- What season might follow this image?

2. 추론 및 상황 해석

- 설명

- 장면의 이전/이후 흐름을 예측하거나, 이유, 결과를 묻는 질문

- 예시

- What is happening or why?
- What will likely happen next?

* TEST 데이터 분석

문제 유형

3. 배경 지식 및 상식

- 설명
 - 문화적 배경, 일반 상식, 특정 사물의 사용 맥락을 외부 지식 기반으로 묻는 질문
- 예시
 - What is the purpose of this object?
 - Which culture is this dish associated with?
 - What does this color symbolize in many cultures?

4. 감정 및 의도 파악

- 설명
 - 사람의 감정, 표정, 행동 동기를 추론하는 질문
- 예시
 - Why might the woman be smiling?
 - Why is the boy looking at the camera?

* 해결 전략

전체 문제의 40%는
지각 및 장면 이해

- 모델은 이미지를 정확하게 이해하거나 자세하고 풍부한 정보가 필요.

사전 학습 모델
사용 가능 범위는
2024년 전

- 추론이 가능한 멀티 모달 모델은 대부분 2024년 후에 출시
- 2024년 전에는 vqa, image captioning 모델이 많음.

추론 모델의
전체 가중치는
3B 미만


- 크고 복잡한 모델은 사용 불가



이미지 캡셔닝과 VQA 출력을 프롬프트로 활용하여, 텍스트 언어 모델이 최종 정답을 선택

* 해결 전략

전체 흐름



* 해결 전략

이미지 증강 - 캡션

- 각 증강 이미지에 대해 개별 캡션을 생성한 후, 하나의 통합 캡션으로 결합.
- 생성된 개별 캡션 중에서 중복되는 캡션은 제거.



원본



밝기 증가



대비 증가



5 크롭

중복 제거

people walking along a path lined with cherry trees in bloom. people
walking along a path lined with cherry trees next to a river...


* 해결 전략

이미지 증강 - VQA

- 하나의 이미지에 대해 6개의 질문을 설정하고, 각각의 질문에 대해 8개의 증강 이미지로 VQA를 수행
- 생성된 VQA에서 중복되는 단어는 제거.

1. What can you see in the image?
2. What is the image that contains?
3. Who is the person in the image?
4. What does the image contain?
5. Where is the image located?
6. Where does the image appear?

추론 모델(text model)이
생성한 질문



원본

밝기 증가

대비 증가



중복 제거


5 크롭



1. What can you see in the image?
(trees, river, people, boats)
2. What is the image that contains?
(cherry blossoms, flowers...)
3. Who is the person in the image?
(group of poeple, family...)
4. What does the image contain?
(flowers, people...)
5. Where is the image located?
(park, river...)
6. Where does the image appear?
(in park, lake...)

* 해결 전략

최종 프롬프트



* 모델 선정

1. Salesforce/blip-vqa-base

- 파라미터 수: 384,672,572 (**0.38B**)
- 공개 날짜: **2022년** 12월
- Input: Image + Text(Question)
- 이미지에 대해서 질문을 통한 정확한 단어, 표현 정보 추출

2. Salesforce/blip-image-captioning-large

- 파라미터 수: 469,732,924 (**0.47B**)
- 공개 날짜: **2022년** 12월
- Input: Image
- 이미지에 대한 전체적인 묘사, 설명 정보 추출

3. google/flan-t5-large

- 파라미터 수: 783,150,080 (**0.78B**)
- 공개 날짜: **2022년** 10월
- Input: Text
- VQA와 캡션을 보고 문제에서 최종 정답을 선택



추론에 사용된 총 파라미터 수: 1,637,555,576개 (1.6B)

* 학습

Fine Tuning전 이미지 캡션



Image Caption: **people standing on a dock near a large ship with mountains in the background**

Q: What type of clothing are the people wearing, and what does it suggest about the climate?

- (A) Light clothing, suggesting a warm and sunny climate
- (B) Swimwear, suggesting a tropical and beach-like climate
- (C) Heavy coats, suggesting a cold and possibly snowy climate
- (D) Raincoats, suggesting rainy and wet weather conditions

➤➤➤ 캡션에 전체적인 묘사만 있고 문제를 맞추기 위한 정보가 매우 부족.

➤➤➤ 날씨, 배경, 사람 복장 등이 포함된 풍부하고 자세한 캡션이 필요

* 학습

학습 데이터

stanford Image Paragraph Captioning dataset

- 이미지당 1개의 **단락(paragraph)** 설명으로 구성
- 총 약 20,000장의 이미지 + 자연어 서술
- 기존의 단문 캡션보다 더 풍부하고 연속적인 설명 제공
- Visual Genome에서 파생된 이미지 사용



There is desk against the wall. The desk as a silver desktop computer on it. The computer has a bright blue button that is lit. Next to the computer is a white landline phone with a black phone cord attached to it. The monitor is siting next to the phone. It is white and is showing a blue screen with a Asian character on the screen. The keyboard is siting in front of the monitor and is black. Next to the monitor, at the end of the desk, there is stuffed penguin. He has yellow feet and a yellow beak with large black and white eyes.



This is a city street corner. The building on the corner is yellow. There are green awnings on the building. There are windows with white frames on the building. The sidewalk is dark brown. The curb is painted yellow. There is a white line painted in the crosswalk. The road is dark gray. The other crosswalk has brown bricks in it.

paper: <https://cs.stanford.edu/people/ranjaykrishna/im2p/index.html>

data download: <https://www.kaggle.com/datasets/vakadanaveen/stanford-image-paragraph-captioning-dataset>

* 학습

Fine Tuning후 이미지 캡션

반복 문제



Image Caption: a group of people are standing on a dock in front of a large white ship with a blue body and a yellow railing on the side of it, and a **red jacket** on the front of it, and a **black and white jacket** on the back of it, and a **red and black jacket** on the back of it, and a **black and white jacket** on the **back of the jacket**, and a **black and red jacket** on the **back of the jacket**, and a **black and white jacket** on the **back of the jacket** and a **black and red jacket** with a **black and blue jacket** on the...

»»» 토큰 수가 많아지고 문장 길이가 길어지면서 특정 단어, 구가 반복되는 문제가 발생.

* 학습

Fine Tuning후 이미지 캡션

대조 탐색 (Contrastive Search)



model.generate(**penalty_alpha=0.6,top_k=4**)



Image Caption: people are standing in front of a large boat that is docked in a body of water on a sunny day, on a clear blue sky, with a few mountains in the background, with snow on them in the background, as well as the mountains in the back, with white capped snow covered peaks, in the foreground and the white top of the building, and the bottom of the building, with a large window, are visible and in the center of the frame, **a man in a blue jacket...**



하이퍼파라미터 조정을 통해 일관되고 반복없는 문장 생성.

* 학습

Fine Tuning후 이미지 캡션



Image Caption: there are a group of people standing outside of a large cruise ship on the water with mountains behind the boat and a large blue body with **snow capped mountains** in the distance behind them... the sky is blue and a few clouds are visible above the mountain... a man in a red coat, and black pants, and a black and white jacket and a red **coat**...

Q: What type of clothing are the people wearing, and what does it suggest about the climate?

- (A) Light clothing, suggesting a warm and sunny climate
- (B) Swimwear, suggesting a tropical and beach-like climate
- ✓ (C) Heavy **coats**, suggesting a cold and possibly **snowy climate**
- (D) Rain**coats**, suggesting rainy and wet weather conditions

* 결론

2024년 전 사전 학습
모델 사용, 추론 모델
3B 미만



이미지 캡션과 VQA를 통해
텍스트 모델이 문제 해결

기존 이미지 캡셔닝
모델의 단순하고 짧은
캡션 문제



Fine Tuning과 이미지 증강
을 통해 정보가 풍부하고 긴
문장 생성

많은 토큰 수와 긴 문장
따른 반복 문제



하이퍼파라미터 조정을 통한
반복 문제 해결

* 결론

최종 점수

Public Score

0.7489
57위



Private Score

0.7644
46위

THANK YOU

감사합니다.